

Katasztrófa–Részvény Korrelációs Adatpipeline

Rövid technikai dokumentáció

1. Bevezetés

A projekt egy teljes, end-to-end adاتمérnöki pipeline, amely azt vizsgálja, hogyan reagáltak a **biztosítótársaságok részvényárai a 2025. januári Los Angeles-i bozóttűzekre**. Két független adatforrást köt össze: a NASA természeti katasztrófa eseményeit (EONET) és a biztosítók napi tőzsdei árait. Az elemzési ablak 2024-12-01–2025-02-28, amelyet egy napi ütemezett futás egészít ki friss adatokkal.

2. A választott architektúra és indoklása

A megoldás egy *lakehouse*-jellegű mintát követ, ahol az extrakció, transzformáció és betöltés (ETL) világosan elkülönül, így minden lépés külön vizsgálható és újrafuttatható.

NASA EONET API + yfinance/Stooq → data/raw (nyers JSON) → pandas transzformáció →
data/processed (CSV) → PostgreSQL (UPSERT) → Metabase / SQL

(a teljes folyamatot az Apache Airflow DAG vezérli, @daily ütemezéssel)


Indoklás.

- **Landing zone (nyers JSON):** a forrás API válaszát változatlanul eltároljuk, mert ez teszi lehetővé a hibakeresést és bizonyítja, hogy a pipeline megőrzi az eredeti, félig strukturált EONET adatot a lapítás előtt.
- **PostgreSQL adattárház:** robusztus, SQL-natív, könnyen konténerizálható, és az `ON CONFLICT (UPSERT)` szemantikával az idempotens betöltés alapja.
- **Apache Airflow:** explicit, DAG-alapú orkesztráció újrapróbálkozással, ütemezéssel és megfigyelhetőséggel; a lépések külön task-okra bonthatók, a transzformáció és betöltés dinamikus task mappinggel (`.expand()`) párhuzamosítható.
- **Adatforrások:** az EONET ingyenes és mélyen beágyazott JSON-t ad (félig strukturált forrás); a részvényárakat elsődlegesen az `yfinance` adja, amely `Stooq` → `Alpha Vantage` → `seed CSV` → szimuláció fallback-láncrea épül, így a futás külső kiesés esetén sem szakad meg.
- **Docker Compose:** egyetlen paranccsal reprodukálja a teljes környezetet (PostgreSQL, Airflow, Metabase); minden paraméter a `.env` fájlban van (nincs hardcode-olt érték).

Idempotencia és ütemezés. A betöltés UPSERT-tel történik, a transzformáció fájlrendszer-szintű gyorsítótárat használ, így ugyanazon nap újrafuttatása nem hoz létre duplikátumot. A DAG adaptív: ütemezett futáskor csak az előző napot dolgozza fel (gyors marad), kézi `{"backfill": true}` konfigurációval pedig a teljes történeti ablakot.

3. Adatmodell (csillagséma)

Az adattárház Kimball-stílusú dimenziós modellt használ **két ténytáblával**, amelyek közös (konformált) dimenziókon osztoznak. A kettős ténytáblás kialakítás külön kezeli a két szemcsézettséget: a részvényár csak kereskedési napokon létezik, a katasztrófa-közelség viszont minden naptári napon, városonként.



1. ábra. Csillagséma: 2 ténytábla (narancs) + 4 konformált dimenzió (kék).

A `dim_company` a betöltés során automatikusan feltöltődik a ténytáblában szereplő tickerekből, így egy friss adattárház is teljesíti a `fact_stock_daily` idegenkulcs-megszorítását. A két ténytáblát elemzéshez SQL nézetek kötik össze (pl. `vw_stock_disaster_price_movement`, amely `LAG()` ablakfüggvénnyel napi % árváltozást is számol).

4. A pipeline futásának eredménye

A `backfill` futás sikeresen lefutott (1083 task-példány, mind *success*), és valós adatot töltött be: **396 részvényt** (6 biztosító × 60 kereskedési nap) és **910 katasztrófát** a 2024-12-01–2025-02-28 ablakban. Az alábbi lekérdezés az Allstate (ALL) reakcióját mutatja a tűzvész körül:

```
SELECT date_key, stock_close_price, pct_close_change,
       nearby_disaster_count, nearest_disaster_distance_km
FROM vw_stock_disaster_price_movement
WHERE ticker = 'ALL' AND city_id = 'US-LOS_ANGELES'
      AND date_key BETWEEN '2025-01-03' AND '2025-01-15'
ORDER BY date_key;
```


date_key	close (USD)	pct %	nearby	dist_km
2025-01-03	191.45	-0.26	0	11905.52
2025-01-06	185.91	-2.89	1	26.48
2025-01-07	186.04	0.07	1	20.06
2025-01-08	191.80	3.10	1	36.49
2025-01-10	180.99	-5.64	0	3580.18
2025-01-13	182.54	0.86	0	12281.47
2025-01-14	186.81	2.34	0	5960.71
2025-01-15	188.03	0.65	0	3574.70

1. táblázat. Allstate (ALL) napi záróár és %-os változás a tűzvész idején.


Értelmezés. A bozóttüzek 2025. január 6–8. között Los Angelesből mindössze 20–36 km-re voltak aktívak (`nearby_disaster_count = 1`). Ezzel egyidőben az Allstate árfolyama január 6-án $-2,89\%$ -ot, majd január 10-én $-5,64\%$ -ot esett (191,80 USD $\rightarrow$ 180,99 USD), a forgalom pedig $\sim 2,4$ millióról $\sim 4,6$ millió darabra ugrott, ami egyértelmű piaci reakció a várható kárfizetésekre. Havi bontásban a januári átlagos aktív katasztrófaszám volt a legmagasabb az időszakban:

év	hónap	átl. aktív kat.	átl. LA-közel	átl. záróár
2024	12	7.7	0.05	250.45
2025	1	11.1	0.20	245.95
2025	2	10.3	0.00	254.72

2. táblázat. Havi katasztrófa-kitettség és átlagos biztosítói záróár.




(a) scheduled_2026-06-19 futás



(b) scheduled_2026-06-20 futás

2. ábra. A két napi ütemezett (@daily) Airflow-futás gráfnézete, ahol minden task állapota *success*.

Napi ütemezett futások. A történeti backfill mellett a DAG @daily ütemezéssel önállóan is fut: minden ütemezett futás az előző napot tölti be (adaptív ablak), így az adattárház naprakész marad. A 2. ábra a két legutóbbi napi futást mutatja az Airflow gráfnézetében: mindkét futás *minden* taskja sikeresen lefutott (`check_api` $\rightarrow$ `extract_stocks/extract_eonet` $\rightarrow$ `transform` $\rightarrow$ `load`), a dinamikus task mapping ([6]) pedig a hat biztosító párhuzamos feldolgozását jelzi.



3. ábra. A Metabase *LA Wildfire Insurance Impact* dashboard a valós, betöltött adatokkal.

Az eredmények a Metabase *LA Wildfire Insurance Impact* dashboardon vizualizálva is elérhetők (a Metabase nyitóoldalára kitűzve, lásd 3. ábra): biztosítói záróár-idősorok, az LA-közei katasztrófák száma (jól látható a januári kiugrás), napi %-os árváltozás, városenkénti kitettség, a csúcs-katasztrófaszám és egy részletező táblázat. Ez a szakasz kizárólag a tűzvész időszakára van szűrve, ezért az újabb adatok itt nem jelennek meg; célja a projekt lényegének bemutatása. Alatta egy hasonló felépítésű szakasz található, amely az elmúlt három hónap adatait emeli ki.

A további dokumentált SQL lekérdezések az `ANALYTICAL_QUERIES.md` fájlban találhatóak, a futtatás lépései pedig a `README.md`-ben.